

LAPORAN ANALISIS

Mini Search Engine

Mata Kuliah: Temu Kembali Informasi

Ujian Tengah Semester (UTS)

Topik Dataset: Komentar Sosial Media tentang Imunisasi Balita

Jumlah Dokumen: 50

Jumlah Term Unik: 526

Teknologi: Python | Sastrawi Stemmer | TF-IDF | Cosine Similarity

DAFTAR ISI

A. Analisis Bobot (IDF)	3
A.1 Perhitungan IDF Kata Kunci 1: "imunisasi"	3
A.2 Perhitungan IDF Kata Kunci 2: "kejang"	3
A.3 Perbandingan & Penjelasan	4
B. Analisis Efek Normalisasi	5
B.1 Hasil Dengan Cosine Normalization	5
B.2 Hasil Tanpa Normalisasi	5
B.3 Perbandingan & Analisis	6
C. Evaluasi Sistem	7
C.1 Skenario Pengujian Query 1	7
C.2 Skenario Pengujian Query 2	8
C.3 Analisis Kualitas Sistem	9

A. Analisis Bobot (IDF)

Pada bagian ini, dipilih 2 kata kunci dari topik kelompok (Komentar Sosial Media tentang Imunisasi Balita) untuk dihitung nilai IDF-nya secara manual. Kata kunci yang dipilih adalah "imunisasi" dan "kejang".

A.1 Perhitungan IDF Kata Kunci: "imunisasi"

Diketahui:

- N (total dokumen) = 50
- df("imunisasi") = 38 (muncul di 38 dokumen)

Dokumen yang mengandung "imunisasi": D1, D3, D4, D6, D7, D8, D11, D12, D13, D14, D15, D16, D17, D18, D19, D20, D21, D23, D24, D25, D29, D30, D31, D32, D33, D34, D35, D36, D37, D39, D40, D41, D42, D43, D44, D46, D49, D50

Rumus IDF (Inverse Document Frequency):

$$IDF(t) = \log_{10}(N / df(t))$$

Langkah perhitungan:

$$\begin{aligned} IDF("imunisasi") &= \log_{10}(50 / 38) \\ &= \log_{10}(1.3158) \\ &= 0.1192 \end{aligned}$$

Hasil: IDF("imunisasi") = 0.1192

Kata "imunisasi" muncul di 38 dari 50 dokumen (76.0% dokumen).

A.2 Perhitungan IDF Kata Kunci: "kejang"

Diketahui:

- N (total dokumen) = 50
- df("kejang") = 5 (muncul di 5 dokumen)

Dokumen yang mengandung "kejang": D26, D27, D35, D45, D46

Langkah perhitungan:

$$\begin{aligned} IDF("kejang") &= \log_{10}(50 / 5) \\ &= \log_{10}(10.0000) \\ &= 1.0000 \end{aligned}$$

Hasil: IDF("kejang") = 1.0000

Kata "kejang" muncul di 5 dari 50 dokumen (10.0% dokumen).

A.3 Perbandingan dan Penjelasan

Kata Kunci	df (Document Freq.)	IDF	% Dokumen
imunisasi	38	0.1192	76.0%
kejang	5	1.0000	10.0%

Dari tabel di atas terlihat bahwa kata "kejang" memiliki nilai IDF yang LEBIH TINGGI dibandingkan kata "imunisasi". Hal ini sesuai dengan prinsip dasar IDF.

PENJELASAN MENGAPA KATA YANG LEBIH JARANG MUNCUL MEMILIKI BOBOT LEBIH TINGGI:

Inverse Document Frequency (IDF) memberikan bobot lebih tinggi pada kata yang jarang muncul di seluruh koleksi dokumen karena:

1. **DAYA PEMBEDA (Discriminative Power):** Kata yang jarang muncul memiliki kemampuan lebih baik untuk membedakan dokumen satu dengan lainnya. Kata yang muncul di hampir semua dokumen (seperti "imunisasi" dalam dataset ini) tidak memberikan informasi yang berguna untuk membedakan dokumen.
2. **NILAI INFORMASI:** Dalam teori informasi, kejadian yang jarang terjadi membawa lebih banyak informasi. Kata yang sangat umum tidak membawa banyak informasi karena kemunculannya sudah diharapkan.
3. **RUMUS LOGARITMIK:** Fungsi $\log_{10}(N/df)$ menghasilkan nilai yang lebih besar ketika df kecil (kata jarang), dan mendekati 0 ketika df mendekati N (kata sangat umum). Ini secara matematis menangkap intuisi bahwa kata umum kurang informatif.

Contoh: "kejang" ($df=5$, $IDF=1.0000$) lebih informatif dibandingkan "imunisasi" ($df=38$, $IDF=0.1192$) karena mampu mengidentifikasi dokumen yang secara spesifik membahas topik kejang pasca imunisasi.

B. Analisis Efek Normalisasi

Pada bagian ini, dibandingkan hasil pencarian query "demam setelah imunisasi" antara yang menggunakan Cosine Normalization dan yang tidak menggunakan normalisasi (hanya dot product).

Query: "demam setelah imunisasi"

Token setelah pre-processing: demam, imunisasi

B.1 Hasil Dengan Cosine Normalization

Cosine Similarity: $\cos(q,d) = (q \cdot d) / (|q| \times |d|)$

Rank	Doc	Score	Token	Komentar (preview)
1	D10	0.219133	9	Alhamdulillah anakku suntik dpt 1 GK sampai d...
2	D22	0.179514	9	bund gimana cara treat bayi yg habis imunasi ...
3	D46	0.145872	13	demam setelah imunisasi di namakan kipi ya mo...
4	D15	0.142788	19	yg imunisasi 18 bulan di suntik mananya bund?...
5	D13	0.123734	18	aku mah milih gk lanjutin imunisasi hanya sam...
6	D27	0.123374	19	anak q kemarin suntik kejang2 sampai tak mau ...
7	D31	0.119904	19	para bunda" tolong ya taat imunisasi bila per...
8	D40	0.102082	28	gara" imunisasi ank saya meninggal di usia 3 ...
9	D34	0.101093	28	alhamdulillah anakku udh full imunisasii udah...
10	D42	0.087800	68	Intinya jgn imunisasi ketika anak sakit entah...

B.2 Hasil Tanpa Normalisasi (Dot Product)

Skor = $q \cdot d$ (tanpa pembagian panjang vektor)

Rank	Doc	Score	Token	Komentar (preview)
1	D42	0.652924	68	Intinya jgn imunisasi ketika anak sakit entah...
2	D31	0.453391	19	para bunda" tolong ya taat imunisasi bila per...
3	D40	0.453391	28	gara" imunisasi ank saya meninggal di usia 3 ...
4	D15	0.450890	19	yg imunisasi 18 bulan di suntik mananya bund?...
5	D32	0.450890	45	FYI buat warga tiktok yg mungkin skip pelajar...
6	D34	0.450890	28	alhamdulillah anakku udh full imunisasii udah...
7	D13	0.446613	18	aku mah milih gk lanjutin imunisasi hanya sam...
8	D46	0.446613	13	demam setelah imunisasi di namakan kipi ya mo...
9	D10	0.432408	9	Alhamdulillah anakku suntik dpt 1 GK sampai d...
10	D22	0.432408	9	bund gimana cara treat bayi yg habis imunasi ...

B.3 Perbandingan dan Analisis

Dokumen	Jml Token	Rank (Norm)	Rank (No Norm)	Perubahan
D10	9	1	9	Naik 8
D13	18	5	7	Naik 2
D15	19	4	4	Tetap

Dokumen	Jml Token	Rank (Norm)	Rank (No Norm)	Perubahan
D22	9	2	10	Naik 8
D31	19	7	2	Turun 5
D32	45	-	5	
D40	28	8	3	Turun 5
D42	68	10	1	Turun 9
D46	13	3	8	Naik 5

ANALISIS MENGAPA DOKUMEN PANJANG CENDERUNG MEMILIKI SKOR LEBIH TINGGI TANPA NORMALISASI:

1. AKUMULASI SKOR: Tanpa normalisasi, skor dihitung sebagai dot product ($q \cdot d$). Dokumen yang lebih panjang memiliki lebih banyak term, sehingga lebih banyak term query yang cocok. Ini mengakumulasi skor yang lebih tinggi terlepas dari relevansi sebenarnya.

2. BIAS PANJANG DOKUMEN: Dalam Vector Space Model, vektor dokumen panjang memiliki magnitude (panjang vektor) yang lebih besar. Dot product secara alami menghasilkan nilai lebih besar untuk vektor dengan magnitude besar.

3. SOLUSI COSINE SIMILARITY: Cosine Similarity mengatasi bias ini dengan membagi dot product dengan perkalian panjang kedua vektor:

$$\cos(q,d) = (q \cdot d) / (|q| \times |d|)$$

Hal ini menormalisasi skor ke rentang [0,1] sehingga yang diukur adalah SUDUT antara dua vektor, bukan magnitudonya. Dokumen yang benar-benar relevan (arah vektor mirip query) akan mendapat skor tinggi terlepas dari panjangnya.

4. HUBUNGAN DENGAN VSM: Dalam Vector Space Model, setiap dokumen dan query direpresentasikan sebagai vektor di ruang multidimensi. Cosine Similarity mengukur kesamaan arah (orientasi) vektor, bukan besarnya. Ini lebih adil karena dokumen pendek yang sangat relevan bisa mendapat skor lebih tinggi dari dokumen panjang yang hanya sedikit relevan.

C. Evaluasi Sistem

Pada bagian ini dilakukan evaluasi sistem dengan 2 skenario pengujian menggunakan kueri yang berbeda. Untuk setiap kueri, ditentukan Ground Truth (dokumen yang benar-benar relevan menurut penilaian manual), kemudian dihitung Precision, Recall, dan F-Measure.

Rumus evaluasi yang digunakan:

$$\begin{aligned}\text{Precision} &= |\text{Relevant n Retrieved}| / |\text{Retrieved}| \\ \text{Recall} &= |\text{Relevant n Retrieved}| / |\text{Relevant}| \\ \text{F-Measure} &= 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})\end{aligned}$$

C.1 Skenario Query 1: "demam setelah imunisasi"

Token setelah pre-processing: demam, imunisasi

Ground Truth (dokumen yang benar-benar relevan menurut penilaian manual):

D8, D10, D13, D15, D22, D27, D31, D34, D40, D42, D45, D46

Total dokumen relevan: 12

Kriteria penentuan ground truth: Dokumen dianggap relevan jika membahas tentang demam sebagai efek/reaksi dari imunisasi, termasuk cara menangani demam pasca imunisasi.

Rank	Doc	Score	Relevan?	Preview
1	D10	0.219133	Ya	Alhamdulillah anakku suntik dpt 1 GK sampai demam ...
2	D22	0.179514	Ya	bund gimana cara treat bayi yg habis imunasi demam...
3	D46	0.145872	Ya	demam setelah imunisasi di namakan kipi ya mom.. j...
4	D15	0.142788	Ya	yg imunisasi 18 bulan di suntik mananya bund?ank k...
5	D13	0.123734	Ya	aku mah milih gk lanjutin imunisasi hanya sampai B...
6	D27	0.123374	Ya	anak q kemarin suntik kejang2 sampai tak mau minum...
7	D31	0.119904	Ya	para bunda" tolong ya taat imunisasi bila perlu le...
8	D40	0.102082	Ya	gara" imunisasi ank saya meninggal di usia 3 bln s...
9	D34	0.101093	Ya	alhamdulillah anakku udh full imunisasi udah lulu...
10	D42	0.087800	Ya	Intinya jgn imunisasi ketika anak sakit entah dema...

Perhitungan metrik evaluasi:

$$\begin{aligned}\text{Retrieved (Top-10)} &= \{\text{D10, D13, D15, D22, D27, D31, D34, D40, D42, D46}\} \\ \text{Relevant (Ground Truth)} &= \{\text{D8, D10, D13, D15, D22, D27, D31, D34, D40, D42, D45, D46}\} \\ \text{Relevant n Retrieved} &= \{\text{D10, D13, D15, D22, D27, D31, D34, D40, D42, D46}\} \\ |\text{Relevant n Retrieved}| &= 10 \\ \\ \text{Precision} &= 10 / 10 = 1.0000 \text{ (100.0\%)} \\ \text{Recall} &= 10 / 12 = 0.8333 \text{ (83.3\%)} \\ \text{F-Measure} &= 2 \times (1.0000 \times 0.8333) / (1.0000 + 0.8333) = 0.9091 \text{ (90.9\%)}\end{aligned}$$

C.2 Skenario Query 2: "vaksin anak balita"

Token setelah pre-processing: vaksin, anak, balita

Ground Truth (dokumen yang benar-benar relevan menurut penilaian manual):

D1, D2, D4, D5, D7, D28, D29, D32, D38, D43, D44, D47

Total dokumen relevan: 12

Kriteria penentuan ground truth: Dokumen dianggap relevan jika membahas tentang vaksinasi/imunisasi yang ditujukan untuk anak atau balita, termasuk prosedur, jenis, dan penjelasan tentang vaksin.

Rank	Doc	Score	Relevan?	Preview
1	D5	0.341231	Ya	Vaksin nya di klinik apa dan di daerah mana...
2	D2	0.228311	Ya	Prosedur apa yg dilalui oleh dokter untuk memastik...
3	D7	0.220143	Ya	Halo kak yg mau tau jenis dan biaya vaksin imunisa...
4	D32	0.168294	Ya	FYI buat warga tiktok yg mungkin skip pelajaran IP...
5	D10	0.041448	Tidak	Alhamdulillah anakku suntik dpt 1 GK sampai demam ...
6	D25	0.041339	Tidak	Alhamdulillah anak akupun udh lulus imunisasi waji...
7	D48	0.027068	Tidak	alhamdulillah ka anakku yg pertama sampe ke dokt...
8	D37	0.026930	Tidak	anakku udah 6 bulan bisa ngk ya imunisasi nya nyus...
9	D17	0.026048	Tidak	Kak, untuk imunisasi 18 bulan di suntik brp kali d...
10	D39	0.025903	Tidak	tetangga aku cucu nya ga di imunisasi, karena nene...

Perhitungan metrik evaluasi:

Retrieved (Top-10) = {D2, D5, D7, D10, D17, D25, D32, D37, D39, D48}
Relevant (Ground Truth) = {D1, D2, D4, D5, D7, D28, D29, D32, D38, D43, D44, D47}
Relevant n Retrieved = {D2, D5, D7, D32}
|Relevant n Retrieved| = 4

Precision = $4 / 10 = 0.4000$ (40.0%)
Recall = $4 / 12 = 0.3333$ (33.3%)
F-Measure = $2 \times (0.4000 \times 0.3333) / (0.4000 + 0.3333) = 0.3636$ (36.4%)

C.3 Ringkasan dan Analisis Kualitas Sistem

Metrik	Query 1	Query 2	Rata-rata
Precision	1.0000 (100.0%)	0.4000 (40.0%)	0.7000 (70.0%)
Recall	0.8333 (83.3%)	0.3333 (33.3%)	0.5833 (58.3%)
F-Measure	0.9091 (90.9%)	0.3636 (36.4%)	0.6364 (63.6%)

INTERPRETASI HASIL EVALUASI:

Rata-rata Precision: 0.7000 (70.0%)

Artinya: Dari semua dokumen yang di-retrieve oleh sistem (top-10), sekitar 70.0% di antaranya benar-benar relevan. Semakin tinggi precision, semakin sedikit "false positive" (dokumen tidak relevan yang ikut ter-retrieve).

Rata-rata Recall: 0.5833 (58.3%)

Artinya: Dari semua dokumen yang benar-benar relevan dalam koleksi, sistem berhasil menemukan 58.3% di antaranya. Semakin tinggi recall, semakin sedikit "false negative" (dokumen relevan yang terlewat).

Rata-rata F-Measure: 0.6364 (63.6%)

F-Measure adalah harmonic mean dari Precision dan Recall, memberikan ukuran keseimbangan antara keduanya. Nilai ini menunjukkan kualitas sistem secara keseluruhan: CUKUP.

KESIMPULAN: Sistem mampu menemukan sebagian besar dokumen relevan, namun masih perlu perbaikan.

Faktor yang mempengaruhi kualitas:

- Kualitas pre-processing (stemming Sastrawi untuk Bahasa Indonesia)
- Penggunaan TF-IDF dengan log frequency weighting
- Cosine Similarity untuk normalisasi panjang dokumen
- Ukuran koleksi dokumen (50 dokumen) yang relatif kecil
- Bahasa informal/slang dalam komentar sosial media